

Corrigé – Exercice 1

Test de détection de signal en grande dimension

Rappel du cadre. On observe $X = (X_1, \dots, X_p)$ avec $X_i \sim \mathcal{N}(\theta_i, 1)$ indépendantes. On teste $H_0 : \|\theta\| = 0$ contre $H_1 : \|\theta\| > \rho$, avec la statistique $\psi(X) = \frac{\sum_{i=1}^p X_i^2 - p}{\sqrt{2p}}$.

Question 1.

$H_0 : \|\theta\| = 0$ est équivalente à $\theta = 0$ (car $\|\theta\| = 0 \Leftrightarrow \theta = 0$). Elle ne contient qu'un seul paramètre : c'est une **hypothèse simple**.

$H_1 : \|\theta\| > \rho$ contient une infinité de valeurs de θ (tous les vecteurs de norme strictement supérieure à ρ) : c'est une **hypothèse composite**.

Question 2.

Sous H_0 , on a $\theta = 0$ donc $X_i \sim \mathcal{N}(0, 1)$ i.i.d. Par définition de la loi du chi-deux,

$$\sum_{i=1}^p X_i^2 \sim \chi^2(p).$$

On rappelle que si $Z \sim \chi^2(p)$, alors $\mathbb{E}[Z] = p$ et $\text{Var}(Z) = 2p$. Par le **théorème central limite**,

$$\psi(X) = \frac{\sum_{i=1}^p X_i^2 - p}{\sqrt{2p}} \xrightarrow[p \rightarrow \infty]{\mathcal{L}} \mathcal{N}(0, 1).$$

Question 3.

Le test $T(X) = \mathbf{1}\{\psi(X) > t\}$ rejette H_0 lorsque $\psi(X) > t$, c'est-à-dire lorsque

$$\frac{\sum_{i=1}^p X_i^2 - p}{\sqrt{2p}} > t \iff \sum_{i=1}^p X_i^2 > p + t\sqrt{2p}.$$

La **région critique** est donc :

$$\mathcal{R} = \left\{ x \in \mathbb{R}^p : \sum_{i=1}^p x_i^2 > p + t\sqrt{2p} \right\}.$$

Il s'agit du complémentaire d'une boule euclidienne fermée centrée à l'origine.

Question 4.

Le test est asymptotiquement de niveau $\alpha = 5\%$ si

$$P_{H_0}(T(X) = 1) = P_{H_0}(\psi(X) > t_{0.05}) \xrightarrow{p \rightarrow \infty} \alpha = 0,05.$$

Puisque $\psi(X) \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$ sous H_0 (question 2), on a

$$P_{H_0}(\psi(X) > t_{0.05}) \approx 1 - \Phi(t_{0.05}) = 0,05,$$

soit $\Phi(t_{0.05}) = 0,95$. On en déduit :

$$t_{0.05} = \Phi^{-1}(0,95) \approx 1,645.$$

En termes de seuil sur $\sum X_i^2$, le test rejette H_0 lorsque

$$\sum_{i=1}^p X_i^2 > p + t_{0.05} \sqrt{2p} \approx p + 1,645 \sqrt{2p}.$$

Question 5.

Définition. L'erreur de type I est la probabilité de rejeter H_0 à tort, c'est-à-dire lorsque H_0 est vraie :

$$\alpha(t) = P_{H_0}(T(X) = 1) = P_{H_0}(\psi(X) > t).$$

Approximation asymptotique. Par la question 2, sous H_0 , $\psi(X) \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$, donc

$$\alpha(t) \approx P(Z > t) = 1 - \Phi(t),$$

où $Z \sim \mathcal{N}(0, 1)$. En particulier, pour $t = t_{0.05} \approx 1,645$, on retrouve $\alpha \approx 5\%$.

Question 6.

Comparaison.

- L'erreur de type I est $\alpha = P_{H_0}(T(X) = 1)$: probabilité de rejeter H_0 quand elle est vraie (faux positif). Comme H_0 est ici simple ($\theta = 0$), il n'y a qu'une seule loi sous H_0 et aucun supremum n'est nécessaire.
- L'erreur de type II est $\gamma = \sup_{\|\theta\| > \rho} P_\theta(T(X) = 0)$: probabilité de ne pas rejeter H_0 quand elle est fautive (faux négatif). Comme H_1 est composite (θ parcourt $\{\|\theta\| > \rho\}$), la probabilité $P_\theta(T(X) = 0)$ dépend de θ et l'on prend le **pire des cas sur** H_1 via le supremum — c'est la garantie la plus défavorable parmi toutes les alternatives admissibles.

Question 7.

On développe $X_i = \theta_i + \varepsilon_i$, donc $X_i^2 = (\theta_i + \varepsilon_i)^2 = \theta_i^2 + 2\theta_i\varepsilon_i + \varepsilon_i^2$. En sommant sur i :

$$\sum_{i=1}^p X_i^2 = \|\theta\|^2 + 2 \sum_{i=1}^p \theta_i \varepsilon_i + \sum_{i=1}^p \varepsilon_i^2.$$

On soustrait p et on divise par $\sqrt{2p}$:

$$\psi(X) = \frac{\sum_{i=1}^p X_i^2 - p}{\sqrt{2p}} = \underbrace{\frac{\|\theta\|^2}{\sqrt{2p}}}_{\text{signal}} + \underbrace{\frac{2 \sum_{i=1}^p \theta_i \varepsilon_i}{\sqrt{2p}}}_{\text{bruit croisé}} + \underbrace{\frac{\sum_{i=1}^p \varepsilon_i^2 - p}{\sqrt{2p}}}_{\text{bruit pur}}.$$

Question 8.

Sous P_θ , les $\varepsilon_i = X_i - \theta_i \sim \mathcal{N}(0, 1)$ sont i.i.d., donc $\sum_{i=1}^p \varepsilon_i^2 \sim \chi^2(p)$.

Le terme $\frac{\sum_{i=1}^p \varepsilon_i^2 - p}{\sqrt{2p}}$ est exactement de la même forme que $\psi(X)$ sous H_0 (question 2). Par le TCL, il converge en loi vers $\mathcal{N}(0, 1)$.

Soit $W = \frac{\sum_{i=1}^p \varepsilon_i^2 - p}{\sqrt{2p}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$. Pour tout $c > 0$, asymptotiquement :

$$P_\theta(|W| \geq c) \approx 2(1 - \Phi(c)).$$

En appliquant ceci avec $c = \frac{\|\theta\|^2}{4\sqrt{2p}}$, on obtient asymptotiquement :

$$P_\theta\left(\left|\frac{\sum_{i=1}^p \varepsilon_i^2 - p}{\sqrt{2p}}\right| \geq \frac{\|\theta\|^2}{4\sqrt{2p}}\right) \leq 2\left(1 - \Phi\left(\frac{\|\theta\|^2}{4\sqrt{2p}}\right)\right).$$

Question 9.

Loi de $\sum \theta_i \varepsilon_i$. Les $\varepsilon_i \sim \mathcal{N}(0, 1)$ sont indépendants, donc $\sum_{i=1}^p \theta_i \varepsilon_i$ est une combinaison linéaire de gaussiennes indépendantes. C'est donc une variable gaussienne d'espérance $\sum_i \theta_i \cdot 0 = 0$ et de variance $\sum_i \theta_i^2 = \|\theta\|^2$. Ainsi :

$$\sum_{i=1}^p \theta_i \varepsilon_i \sim \mathcal{N}(0, \|\theta\|^2).$$

Majoration. On peut écrire $\sum_i \theta_i \varepsilon_i = \|\theta\| \cdot Z$ avec $Z \sim \mathcal{N}(0, 1)$. Donc :

$$\begin{aligned} P_\theta\left(\left|\frac{2 \sum_{i=1}^p \theta_i \varepsilon_i}{\sqrt{2p}}\right| \geq \frac{\|\theta\|^2}{4\sqrt{2p}}\right) &= P\left(|2\|\theta\|Z| \geq \frac{\|\theta\|^2}{4}\right) \\ &= P\left(|Z| \geq \frac{\|\theta\|}{8}\right) \\ &= 2\left(1 - \Phi\left(\frac{\|\theta\|}{8}\right)\right). \end{aligned}$$

(Le passage de la première à la deuxième ligne utilise la division par $\sqrt{2p}$ au numérateur et au dénominateur, qui se simplifie.)

Question 10.

Notons $A = \frac{\|\theta\|^2}{\sqrt{2p}}$, $B = \frac{2 \sum_i \theta_i \varepsilon_i}{\sqrt{2p}}$, $C = \frac{\sum_i \varepsilon_i^2 - p}{\sqrt{2p}}$, de sorte que $\psi(X) = A + B + C$.

Argument. La condition $A > 2t_{0.05}$ signifie $\frac{A}{2} > t_{0.05}$. Si $|B| < \frac{A}{4}$ et $|C| < \frac{A}{4}$, alors :

$$\psi(X) = A + B + C > A - \frac{A}{4} - \frac{A}{4} = \frac{A}{2} > t_{0.05},$$

donc $T(X) = 1$. Par contraposée, en notant $\delta = \frac{A}{4} = \frac{\|\theta\|^2}{4\sqrt{2p}}$:

$$\{\psi(X) \leq t_{0.05}\} \subseteq \{|B| \geq \delta\} \cup \{|C| \geq \delta\}.$$

Par l'inégalité de l'union et les majorations des questions 8 et 9 :

$$P_\theta(\psi(X) \leq t_{0.05}) \leq P_\theta(|B| \geq \delta) + P_\theta(|C| \geq \delta) \leq 2\left(1 - \Phi\left(\frac{\|\theta\|}{8}\right)\right) + 2\left(1 - \Phi\left(\frac{\|\theta\|^2}{4\sqrt{2p}}\right)\right).$$

Question 11.

L'erreur de type II est $\gamma = \sup_{\|\theta\| > \rho} P_\theta(T(X) = 0)$. La majoration de la question 10 s'applique pour tout θ vérifiant $\frac{\|\theta\|^2}{\sqrt{2p}} > 2t_{0.05}$. Les deux termes de la borne sont **décroissants** en $\|\theta\|$, donc le supremum sur $\|\theta\| > \rho$ est atteint à la frontière $\|\theta\| = \rho$:

$$\gamma \leq 2\left(1 - \Phi\left(\frac{\rho}{8}\right)\right) + 2\left(1 - \Phi\left(\frac{\rho^2}{4\sqrt{2p}}\right)\right).$$

Question 12.

On veut $\gamma \leq 0,05$. On impose que chaque terme soit $\leq 0,025$, ce qui donne deux conditions :

$$2\left(1 - \Phi\left(\frac{\rho}{8}\right)\right) \leq 0,025 \quad \text{et} \quad 2\left(1 - \Phi\left(\frac{\rho^2}{4\sqrt{2p}}\right)\right) \leq 0,025.$$

Première condition : $\Phi\left(\frac{\rho}{8}\right) \geq 0,9875$, soit $\frac{\rho}{8} \geq \Phi^{-1}(0,9875) \approx 2,24$, donc $\rho \geq 18$. C'est une condition **ne dépendant pas de p** .

Deuxième condition : $\frac{\rho^2}{4\sqrt{2p}} \geq \Phi^{-1}(0,9875) \approx 2,24$, soit

$$\rho^2 \geq 4 \cdot 2,24 \cdot \sqrt{2p} \approx 8,96 \sqrt{2p},$$

donc $\rho \geq C p^{1/4}$ pour une constante $C > 0$.

La condition dominante (pour p grand) est :

$$\rho \gtrsim C p^{1/4}.$$

Il faut aussi vérifier la condition de la Q10 : $\frac{\rho^2}{\sqrt{2p}} > 2t_{0.05} \approx 3,29$, soit $\rho^2 > 3,29\sqrt{2p}$, ce qui est du même ordre et donc automatiquement satisfait.

Question 13.

Interprétation. Ce résultat établit une **condition suffisante** : dès que $\|\theta\| = \rho \gtrsim p^{1/4}$, le test T contrôle simultanément les erreurs de type I et de type II au niveau 5%. Il suffit donc que le signal soit d'ordre $p^{1/4}$ pour que la détection fonctionne — mais ce n'est pas, à ce stade, une condition nécessaire : on n'a pas montré qu'aucun test ne pouvait faire mieux.

Intuition. En dimension p , le bruit $\sum \varepsilon_i^2$ est d'ordre p avec des fluctuations d'ordre $\sqrt{p}$. Le signal $\|\theta\|^2 = \rho^2$ doit dominer ces fluctuations, ce qui exige $\rho^2 \gtrsim \sqrt{p}$, soit $\rho \gtrsim p^{1/4}$: c'est bien le bon **ordre de grandeur**.

Remarque (hors sujet). La réciproque — montrer qu'*aucun* test ne peut détecter un signal d'ordre $\ll p^{1/4}$ (borne inférieure, dite minimax) — relève d'arguments différents (typiquement Le Cam ou Fano) et n'est pas demandée ici.